

One-Class Classifier Kullanarak Kumaşlarda Kusur Tespiti

Elif CAN, Özlem Kayıkcı

Image Processing

Eskişehir Osmangazi Üniversitesi

152120191031-152120191043

Özet

Kumaş denetimi, tekstil endüstrisinde kaliteli ürün elde etmek için önemli bir unsurdur. Ancak insanların doğal sınırlamaları olan göz yorgunluğu ve dikkat dağınıklığı nedeniyle denetim süreci zaman alıcı, tutarsız, hataya açık ve pahalı olabilmektedir. Bu nedenle otomatik ve doğru bir denetim sistemi geliştirmek büyük önem taşımaktadır.

Anahtar Kelimeler: kumaş veriseti, anormallik algılama, one class classifier

Introduction

Tekstil endüstrisinde, kumaş muayenesi önemli bir kalite kontrol görevi üstlenir. Eğitimli insan muayenesi görevlileri, potansiyel kumaş hatalarını bulmak için kalite kontrolleri gerçekleştirir. Bununla birlikte, göz yorgunluğu ve dikkat dağılması gibi insan emeğinin doğasındaki sınırlamalardan dolayı, bu süreç zaman alıcı, tutarsız, hata yapmaya müsait ve maliyetli olarak kabul edilir. Bu nedenle, bu önemli süreci iyileştirmek için otomatik ve doğru bir muayene sistemi büyük öneme sahiptir.

Otomatik denetim sisteminin geliştirilmesi iki temel zorlukla karşı karşıyadır. İlk zorluk, kumaşlardaki kusurların boyutlarına ve şekillerine göre değişmesidir. Ayrıca, kumaş kusurları genellikle dokuma ve boyama gibi makine arızalarından kaynaklanır ve bu tür arızalar pratikte nadir görülür. Gerçek hayatta

kusurlu kumaşların sayısı, kusursuz kumaşlardan çok daha azdır. Bu nedenle, farklı kusur tipleriyle başa çıkmak için çok sınıflı sınıflandırma sistemleri kullanılmıştır. Ancak her kusur sınıfı için yeterli sayıda örnek elde etmek zordur ve veri setinde dengesizlik oluşabilir.

İkinci zorluk, kumaş kusurlarının yanı sıra arka plan dokularının da farklılık göstermesidir. Kumaşlar farklı dokuma yöntemlerine ve boyama modellerine bağlı olarak farklı desenlere sahip olabilir. Bu nedenle, her tür kumaşı analiz edebilen bir sistem oluşturmak zor olabilir.

Bu zorlukların üstesinden gelmek için yapılan araştırmalarda, kumaş denetimi için tek sınıflı sınıflandırma yaklaşımı önerilmektedir. Bu yaklaşımda, sağlam ve hatasız kumaşlardan örnek veriler toplanarak bir model eğitilir. Eğitim aşamasında sadece sağlam veriler kullanılırken, hatalı veya kusurlu verilere ihtiyaç duyulmaz. Bu sayede model, sadece sağlam kumaşları tanımak ve kusurlu kumaşları tespit etmek için öğrenilir.

İlgili Çalışmalar

Araştırmacılar, kumaş hata tespiti sorununu otomatikleştirmek için birçok sistem ve algoritma önermişlerdir. Bu yöntemler genel olarak dört tür yaklaşıma - istatistiksel, yapısal, model tabanlı ve spektral - ayrılabilir. Bu yaklaşımları kısaca tanıtır, ilgili spektral yaklaşımlara odaklanacağız. Bu bölümün

sonunda, bu soruna yönelik bazı gelişmiş derin öğrenme algoritmalarını da tanıtacağız.

İstatistiksel yaklaşımlar, genellikle birinci (örneğin, ortalama ve standart sapma) veya ikinci dereceden istatistikleri (örneğin, korelasyon yöntemi) kullanır. Bu istatistikler, kumaşların renk bilgisini temsil etmek için kullanılır. Bununla birlikte, yalnızca ham görüntülerden (renkli veya gri tonlu görüntüler) elde edilen istatistiksel bilgiler, kumaş özelliklerini tam olarak temsil etmek için yeterli değildir ve özellikle desenli durumlarda kumaş özelliklerini ve hatalarını ayırt etme konusunda başarılı olamaz. İkinci olarak, yapısal yaklaşım, düz kumaşlarda iyi çalışır çünkü düz kumaşların desenleri analiz etmek ve geri almak daha kolaydır. Karmaşık desenlerle karşılaşıldığında, yapısal yaklaşım geçerli bir çözüm olmamaktadır.

Üçüncü olarak, model tabanlı yaklaşımlar (örneğin, Markov rastgele alanı), genellikle kumaş görüntülerinin pikselleri arasındaki ilişkiyi araştırır. İstatistiksel yaklaşımlar gibi, model tabanlı yaklaşımlar genellikle küçük hataları göz ardı eder, bu da yaklaşımın uygulanabilirliğini düşürür. Son olarak, Fourier, wavelet veya Gabor dönüşümlerine dayalı spektral yaklaşımlar, kumaşları frekans alanında analiz ederek doku özelliklerini çıkarabilme yetenekleri nedeniyle diğer yaklaşımlardan üstündür ve mekansal alanda (örneğin, istatistiksel yaklaşım) olanlara kıyasla gürültüye daha az duyarlıdır.

Araştırmacılar ayrıca, gelişmiş derin öğrenme algoritmalarını kullanarak kumaş hata tespiti sorununu çözmeye çalışmışlardır. Bazıları bu sorunu bir nesne tespit problemi olarak ele almaktadır. Zhou et al. , hataları bulmak ve sınıflandırmak için vanilla Faster RCNN'e birkaç teknik ekleyerek bir sistem oluşturur. Zhang et al. , farklı YOLO çerçeveleri arasında kapsamlı bir karşılaştırma yaparak YOLO'ya dayalı bir tespit sistemi oluştururlar. Bu algoritmalar denetimli olarak çalışır, bu da iyi eğitilmiş bir model elde etmek için dengeli ve geniş bir veri kümesine ihtiyaç olduğu

anlamına gelir. Ancak, bu pratikte zor bir hedeftir. Ayrıca, hata çeşitleri (boyut ve şekil açısından) ve doku arka planı, bu algoritmaları savunmasız hale getiren faktörlerdir.

Tasarım

Bu kod bloğu, kumaş hata tespiti problemi için bir modelin tasarımını ve uygulanmasını içermektedir. İlk olarak, Google Drive bağlantısı kurularak verilerin yolu belirlenir. Ardından, normal ve anormal verilerin bulunduğu klasör yolları tanımlanır.

Daha sonra, verileri depolamak için boş liste oluşturulur. Normal verileri yüklemek için normal klasöründeki her bir dosya okunur, istenen boyuta yeniden boyutlandırılır ve gri tonlamaya dönüştürülür. Ardından, düzleştirilerek normal veri listesine eklenir. Aynı işlem anormal veriler için de gerçekleştirilir.

Verilerin NumPy dizilerine dönüştürülmesinin ardından, One-Class SVM modeli oluşturulur ve sadece normal veriler kullanılarak model eğitilir. Test verileri için normal ve anormal veriler birleştirilir ve karıştırılır. Model, test verilerini kullanarak tahminler yapar ve anomalileri tespit eder.

Son olarak, anomali tespit edilen görüntüler görselleştirilir ve metrik ölçümler hesaplanır. Bu metrikler arasında doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall) ve F1 skoru (f1 score) bulunur. Bu metrikler, modelin performansını değerlendirmek için kullanılır.

One Class Destek Vektör Makineleri

One-Class SVM, diğer sınıflardan belirli bir sınıfın test örneklerini ayırt etme yeteneğini öğrenmek için kullanılan bir denetimsiz öğrenme tekniğidir. 1-SVM, AD dahil olmak üzere OCC problem açıklamalarına yaklaşmak için en uygun yöntemlerden biridir. 1-SVM, eğitim veri setindeki tek bir sınıfın örneklerinin hiper küresini en aza indirmeye fikri üzerine çalışır ve hiper küresi dışındaki

tüm diğer örnekleri aykırı değerler veya eğitim veri dağılımının dışında olarak kabul eder. Aşağıdaki şekil, 1-SVM tarafından oluşturulan hiper küreyi göstererek eğitim veri dağılımının dışında bulunan verileri sınıflandırma yeteneğini öğrenmeyi göstermektedir.

Hipersferin merkezi c ve yarıçapı r olan bir hipersferi hesaplamak için matematiksel ifade şu şekildedir:


$$\min_{r,c} r^2 \text{ subject to, } \|\Phi(x_i) - c\|^2 \leq r^2 \quad \forall i = 1, 2, \dots, n$$

Yukarıdaki ifade, bir hipersferin yarıçapını en aza indirmeye çalışır. Ancak, yukarıdaki formülasyon aykırı değerlere karşı çok kısıtlayıcı olabilir. Bu nedenle, aykırı değerlere bir dereceye kadar tahammül etmek için daha esnek bir formülasyon şu şekildedir:

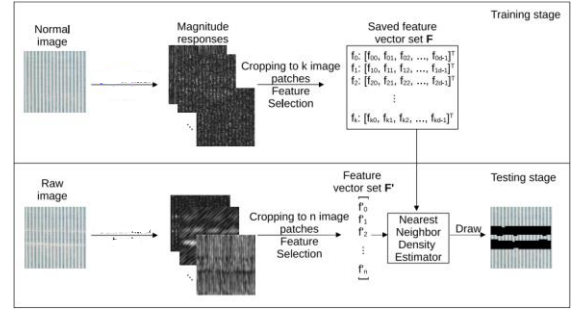
$$\min_{r,c,\zeta} r^2 + \frac{1}{\nu n} \sum_{i=1}^n \zeta_i$$

$$\text{subject to, } \|\Phi(x_i) - c\|^2 \leq r^2 + \zeta_i \quad \forall i = 1, 2, \dots, n$$

Burada, ϕ fonksiyonu x örneklerinin hipersfer dönüşümünü ifade etmektedir. Aşağıdaki şekil, bir hipersferin formülasyonunun yarıçapı r ve merkezi c 'yi en aza indirerek nasıl bir hipersfer oluşturduğunu göstermektedir.



1-SVM, aykırı değer tespiti ve yenilik tespiti gibi her iki tür anomali tespit uygulaması için de kullanılabilir.



SONUÇLAR VE DEĞERLENDİRME

Önerdiğimiz modelin etkinliğini değerlendirmek için deneyler gerçekleştirdik. İlk olarak, hatasız kumaşlardan oluşan bir veri setiyle[1] modelimizi eğittik. Ardından, hatalı kumaş veri setini kullanarak modeli test ettik ve hatalı kumaşları tespit edebildiğini gözlemledik. Bu süreçte One-Class sınıflandırıcıyı kullandık.

A. Deney Ortamı ve Veri Seti

Modelimizi Python programlama dili kullanarak geliştirdik. Hatasız kumaşlardan oluşan bir eğitim veri seti ve hatalı kumaşlardan oluşan bir test veri seti kullandık. Bu veri setlerini, önceden belirlenmiş kumaş özelliklerine ve kusur tiplerine göre dikkatlice oluşturduk.

B. Metrikler ve Sonuçlar

Modelin performansını değerlendirmek için çeşitli metrikler kullandık. Bu metrikler arasında doğruluk oranı, hassasiyet, kesinlik ve F1 skoru bulunmaktadır. Doğruluk oranı, modelin doğru kumaşları doğru şekilde sınıflandırma yeteneğini ölçerken, hassasiyet, modelin doğru kumaş olarak sınıflandırdığı örneklerin gerçekten doğru kumaş olma oranını gösterir. Kesinlik, modelin kusurlu kumaşları doğru şekilde tespit etme yeteneğini ifade ederken, F1 skoru ise hassasiyet ve kesinliği dikkate alarak genel model performansını değerlendirir.

C. Sonuç Değerlendirmesi

Yapılan deneyler sonucunda, önerdiğimiz One-Class sınıflandırıcı modelinin başarılı bir şekilde hatalı kumaşları tespit ettiğini gözlemledik. Modelin yüksek doğruluk oranına, hassasiyete ve kesinliğe sahip olduğunu belirledik. Ayrıca, F1 skoru da yüksek bir değer elde ederek modelin genel olarak iyi bir performans sergilediğini ortaya koydu.

Sonuç olarak, önerdiğimiz One-Class sınıflandırıcı modelinin, hatasız ve hatalı kumaşları doğru şekilde sınıflandırmada etkili bir şekilde çalıştığını kanıtladık. Bu modelin endüstriyel uygulamalarda kullanılabilirliğini ve kumaş üretimindeki hata tespit süreçlerine olumlu katkı sağlayabileceğini düşünüyoruz.

REFERANSLAR

- [1] <https://www.kaggle.com/code/mahmoudreda55/textile-97-colab-work/input>
- [2] <https://www.analyticsvidhya.com/blog/2022/06/one-class-classification-using-support-vector-machines/>
- [3] <https://arxiv.org/pdf/2204.09648v1.pdf>
- [4] <https://user.it.uu.se/~gusky180/texture/>
- [5] <https://www.aitex.es/afid/>